



RSDO-5 TERMINOLOŠKI PORTAL SMERNICE IN NAVODILA ZA IZDELAVO TERMINOLOŠKIH VIROV

Pripravili: Mateja Jemec Tomazin, Miro Romih, Simon Atelšek, Tanja Fajfar, Jera Sitar, Mojca

Žagar Karer

Verzija: 2.0

Datum: 27. 2. 2023





Vsebina

1 Izhodišča	3
2 Terminološki portal	5
2.1 Splošno o metajeziku terminološkega portala	5
2.2 Oblikovanje terminološkega vira	7
2.3 Vključeni terminološki viri	8
2.4 Uporabniki	8
2.5 Uporabniške vloge	9
3 Iskanje	11
3.1 Osnovno iskanje	14
3.2 Napredno iskanje	14
3.3 Prikaz in razvrščanje zadetkov	15
3.4 O terminu	17
3.5 O slovarju	17
4 Luščenje	19
4.1 Postopek luščenja	19
4.2 Seznam luščenj	24
4.3 Dodajanje in urejanje luščenj	24
5 Urejanje	26
5.1 Struktura slovarskega sestavka	26
5.2 Faze urejanja	28
5.3 Nov slovar	29
6 Svetovanje	33
6.1 Pošiljanje vprašanj	
6.2 Objava odgovorov	
7 Administracija	
7.1 Osnovne nastavitve	
7.2 Povezave s portali	
8 Kalafan	36





1 Izhodišča

Sodobna slovenska terminologija nastaja na različnih področjih, kar dokazujejo predvsem različni terminološki viri, zlasti mnogi terminološki slovarji, poleg tega pa je terminološka veda tudi živahno raziskovalno področje. O terminologiji kot naboru terminov govorimo vedno v okviru določenega strokovnega področja. V zadnjih letih se je okrepila dejavnost terminološkega svetovanja, ki dopolnjuje primanjkljaje na strokovnih področjih, ki še nimajo svojih terminoloških slovarjev ali drugih virov, namenjenih strokovnim uporabnikom.

Izdelava terminološkega vira ne poteka samo v organizirani skupini, ki jo vodi terminolog (najpogosteje jezikoslovec, ki je specializiran za terminologijo), ampak se potrebe po urejanju terminologije pojavljajo vedno znova ob različnih priložnostih, pogosto so urejeni terminološki seznami tudi eden od rezultatov raziskovalnih projektov, nastajajo kot projektno delo v času študija, mnogi projekti pa se celo začnejo z željo po poenotenju terminologije pred začetkom raziskovalnega dela. Da bi bilo terminološko delo čim lažje organizirati, smo pripravili Slovenski terminološki portal, ki omogoča različne storitve. Izdelava terminološkega vira, še posebej terminološkega slovarja, je namreč veliko lažja s primernim slovaropisnim orodjem, zato terminološki portal ponuja orodja za vse faze izdelave terminološkega vira, kar bomo natančneje opisali v nadaljevanju.

Na osnovi analize drugih spletišč s terminološkimi vsebinami in spletnih mest, ki omogočajo izmenjavo terminoloških podatkov, smo pri zasnovi sodobnega terminološkega portala upoštevali naslednja splošna izhodišča:

- združiti čim več specializiranih enojezičnih in večjezičnih terminoloških virov na enem mestu,
- vzpostaviti urejene in čim bolj standardizirane terminološke vire,
- ponuditi prostodostopno infrastrukturo za uporabo in izdelavo novih terminoloških virov,
- področnim strokovnjakom, prevajalcem, lektorjem, študentom in drugim uporabnikom ponuditi zmogljiva, a preprosta orodja, ki jim bodo omogočili čim boljše podatke,
- ponuditi možnost izvoza odprtodostopnih podatkov vsem registriranim uporabnikom terminološkega portala,
- omogočiti programsko povezljivost podatkov na terminološkem portalu za potrebe zunanjih spletnih storitev (npr. pomnilnikov prevodov),





• ponuditi odprti dostop do razvite programske kode in posameznih modulov na javnem repozitoriju.





2 Terminološki portal

Pri zasnovi novega terminološkega portala smo izhajali iz rešitev obstoječih terminoloških portalov, tako domačih (npr. <u>Terminologišče</u>, <u>Termania</u>, <u>Evroterm</u>) kot tudi številnih tujih (<u>Hrvatski terminološki portal</u>, <u>EuroTermBank</u>). Terminološki portal z vsemi funkcionalnostmi je na voljo uporabnikom kot samostojna prostodostopna spletna storitev, v katero je vključenih večje število terminoloških virov, ki jih dopolnjujejo povezani terminološki slovarji s portalov <u>Termania</u> in <u>Terminologišče</u>. Tako kot celoten terminološki portal so v obliki samostojne spletne storitve z možnostjo lastne namestitve ponujeni tudi nekateri specializirani moduli, kot je npr. modul za luščenje terminoloških kandidatov iz besedil, na spletnem mestu <u>GitHub Clarin.si</u>.

Za pozitivno uporabniško izkušnjo je poleg funkcionalnosti v tehničnem smislu zelo pomemben tudi videz. Ne samo barve, pisave, velikosti in oblike posameznih grafičnih elementov na strani, pomembna je tudi njihova razporeditev in povezave med njimi ter posameznimi spletnimi stranmi. Pri izdelavi terminološkega portala smo upoštevali pravila odzivnega oblikovanja in prilagoditve strani uporabnikom s posebnimi potrebami.

Izhajali smo iz naslednjih smernic za oblikovanje spletnih vsebin, ki omogočajo dostopnost ranljivim skupinam:

- W3C (Strategies, standards, resources to make the Web accessible to people with disabilities) https://www.w3.org/WAI/
- Get Resources for Content Writers https://www.w3.org/WAI/roles/writers/
- Tips for Getting Started Designing for Web Accessibility https://www.w3.org/WAI/tips/designing/
- Web Accessibility Tutorials for Developers https://www.w3.org/WAI/tutorials/

Terminološki portal deluje v spletnih brskalnikih Google Chrome, Mozilla Firefox, Microsoft Edge in Safari.

Vsi ustvarjeni podatkovni viri in razvita programska koda so dostopni pod licencama CC BY-SA-4.0 in Apache 2 in shranjeni na repozitorijih <u>Clarin.si</u> ter <u>GitHub</u>.

2.1 Splošno o metajeziku terminološkega portala

Za lažjo uporabo terminološkega portala so definirani termini, ki so uporabljeni v storitvi luščilnika in urejevalnika.





Opredelitev osnovnih terminov

definicija = strukturiran daljši opis pojma, ki določi nadrejeni pojem ali pojmovno skupino, navadno v eni povedi in brez velike začetnice na začetku ter končnega ločila na koncu (sinonim: **razlaga**)

geslovnik = seznam terminov, ki so vključeni v terminološki vir

glosar → slovar

iztočnica = termin v slovenskem jeziku, ki je na začetku vsakega slovarskega sestavka

krajšava = kratica ali okrajšava

kratica = beseda, nastala iz sklopljenih, navadno začetnih črk ali zlogov večbesedne zveze, npr. CD, PGD

luščenje terminologije = identifikacija eno- in večbesednih terminoloških kandidatov v specializiranem korpusu s pomočjo namenskega programa

okrajšava = niz črk, ki označuje besedo ali besedno zvezo, navadno zapisana z malimi črkami, ki se končajo s piko, npr. prid., sam.

podpodročje = ožje zamejena strokovna dejavnost, v kateri se uporablja terminologija, predstavljena v terminološkem viru

področje = strokovna dejavnost, v kateri se uporablja terminologija, predstavljena v terminološkem viru

področna oznaka = oznaka, ki izbrano skupino pojmov znotraj terminološkega vira uvrsti na določeno ožje področje

poimenovanje → termin

pojasnilo = zunajjezikovne okoliščine, ki niso del pojma, ponujajo pa dodatne informacije v zvezi z njim, npr. letnica sprejema pravnega predpisa

pojem = miselna enota, ki jo označuje termin

pojmovnik → slovar

povezani termin = termin, ki je pojmovno blizu definiranemu terminu, npr. nadrejeni termin ali istovrstni termin

razlaga → definicija

sinonim = termin v razmerju do drugega termina, ki označuje isti pojem (sinonim: sopomenka)





slovar = jezikovni vir, v katerem so besede praviloma razvrščene po abecedi in razložene (sinonima: glosar, pojmovnik)

slovarski sestavek = celotno besedilo vnosa, ki zajema termin, definicijo, tujejezični termin, sinonim, morebitne povezane termine

sopomenka → sinonim

specializirani korpus = korpus besedil z določenega strokovnega področja, ki je osnova za luščenje terminoloških kandidatov

splošni slovar = jezikovni vir, ki razlaga in prikazuje rabo besed določenega jezika

strokovni izraz → termin

termin = beseda ali besedna zveza, ki označuje pojem (sinonima: poimenovanje, strokovni izraz)

terminološki kandidat = beseda ali besedna zveza, ki se v strokovnih in znanstvenih besedilih določenega strokovnega področja pogosto pojavlja, zato je uvrščena med rezultate luščenja terminologije

terminološki slovar = jezikovni vir, v katerem je zbrana terminologija določenega strokovnega področja in ponavadi temelji na pojmovnem načelu, poleg definicij pa navadno vsebuje tudi tujejezične termine

terminološki vir = urejena terminologija določenega strokovnega področja, ki vključuje tudi informacije glede na izbrano vsebinsko zasnovo

tuji termin = termin, ki v drugem jeziku, npr. angleščini, hrvaščini, označuje isti pojem kot v slovenščini

2.2 Oblikovanje terminološkega vira

Delo praviloma poteka v skupini strokovnjakov z nekega področja, npr. informatikov, botanikov, davčnih strokovnjakov, lahko pa področni strokovnjak tudi sam izdela terminološki vir.

Pred začetkom dela je pomembno najprej določiti naslovnika terminološkega vira, torej, kdo bo najpogosteje terminološki vir uporabljal, kar določa informacije, ki so v takšen vir vključene. Posamezne storitve na terminološkem portalu so bile oblikovane prav z namenom pomoči takšnim skupinam in posameznikom, da bi si sami pripravili seznam terminoloških kandidatov ter ga nato dopolnjevali, dodajali informacije v urejevalniku, jih tam urejali ter terminološki vir





na koncu tudi objavili, s čimer bi postal dostopen vsem uporabnikom portala. Shema slovarskega sestavka je dovolj široka, da lahko vsaka skupina strokovnjakov poljubno dodaja tiste elemente, ki jih želi in potrebuje v svojem terminološkem viru.

2.3 Vključeni terminološki viri

Čeprav je Slovenski terminološki portal zasnovan kot odprto mesto za urejanje terminologije, pa seveda ne spreminja obstoječih pravic avtorjev v že nastalih virih, zato so nekateri terminološki viri odprti in jih lahko registrirani uporabniki prenesejo na svoje računalnike, drugi pa so agregirani s pomočjo skupnega iskalnika – zato bodo dostopni tudi slovarji s <u>Terminologišča</u> in <u>Termanie</u>.

Vsi viri, ki so bili pridobljeni v okviru projekta RSDO, so bili pretvorjeni v enotno strukturo, saj je tako olajšano prikazovanje, urejanje, pretvarjanje, uvažanje, izvažanje, izmenjevanje podatkov.

2.4 Uporabniki

Uporabniki lahko iščejo po terminološkem portalu brez registracije. Za uporabo drugih storitev - luščenja, urejanja terminoloških virov, komentiranja in zastavljanja terminoloških vprašanj v svetovalnici pa je ob prvem obisku potrebna registracija, ob vseh naslednjih pa prijava.

Vsak registrirani uporabnik bo lahko sam ustvaril in urejal svoj terminološki vir. Da pa bi na portalu zagotovili čim bolj kakovostne podatke, je glede na uredniško politiko portala poleg samodejnega preverjanja predvideno tudi potrjevanje virov pred objavo na zunanjem delu terminološkega portala, ki ga opravi skrbnik terminoloških virov. Samodejno preverjanje vključuje formalno/tehnično preverjanje in avtomatska opozorila uredniku določenega terminološkega vira o morebitnih nepravilnostih (npr. manjkajočih vnosih ali identičnih definicijah). Skrbnik terminoloških virov pa lahko v skladu s politiko terminološkega portala še ročno potrdi in dokončno objavi terminološki vir.

Obstajajo različne klasifikacije področij, vendar se je v praksi pokazalo, da nobena od njih ni dovolj preprosta in blizu uporabnikom, ki niso vešči različnih klasifikacijskih sistemov, po drugi strani pa ne pokriva vseh potreb za gradnjo organizirane terminološke zbirke. Za Slovenski terminološki portal je bil pripravljen samostojen seznam področij, ki pa ima pripisana tudi ustrezna področja v klasifikacijah <u>CERIF</u> in <u>Eurovoc</u>.





Uporabnikom je poleg predlaganega seznama podpodročij omogočeno tudi dodajanje novih podpodročij z namenom čim bolj jasne umestitve terminoloških virov. Osnovno področje mora biti obvezno izbrano iz spustnega seznama področij, podpodročja pa lahko registrirani uporabniki prosto vpisujejo, če ga na spustnem seznamu predlaganih podpodročij ne najdejo. Nova podpodročja mora potrditi administrator portala. Uvrstitev terminološkega vira v področje predlaga administrator terminološkega vira. Pred potrditvijo skrbnika terminoloških virov in objavo na zunanjem delu terminološkega portala je lahko opravljen še vsebinski pregled slovarskih sestavkov in reševanje morebitnih komentarjev, če bi jih uredniki terminološkega vira zastavili skrbniku terminoloških virov ali administratorju portala. Tudi brez potrditve pa bo administrator terminološkega vira svoj vir lahko vedno uporabljal v zasebnem delu terminološkega portala ali ga izvozil in shranil na svojem računalniku.

Na zunanjem delu terminološkega portala bo uporabnikom vedno na voljo le zadnja verzija objavljenega terminološkega vira. Kadar so v terminološkem viru dodane večje vsebinske dopolnitve, je smiselno terminološki vir izvoziti in ga tudi naložiti na repozitorij Clarin.si, kar omogoča sledljivost sprememb in zanesljivost vira.

2.5 Uporabniške vloge

Terminološki portal je tudi po zaključku projekta vodena in vsebinsko ter tehnično podprta storitev. V nadaljevanju so opisane posamezne vloge na terminološkem portalu.

Administrator portala – glavni urednik vseh vsebin na portalu, ki ima vse pravice dopolnjevanja, spreminjanja, brisanja

Skrbnik terminoloških virov – glavni urednik vseh terminoloških virov, ki lahko dovoli objavo terminološkega vira na zunanjem delu terminološkega portala, dodaja uporabnike, da smejo urejati terminološki vir, ureja področja in podpodročja

Skrbnik svetovalnice – glavni urednik svetovalnice, ki vodi svetovalnico in dodeljuje terminološka vprašanja posameznim svetovalcem (samo pri samostojnih namestitvah terminološkega portala, ki niso povezani s <u>Terminološko svetovalnico</u> Inštituta za slovenski jezik Frana Ramovša ZRC SAZU)

Svetovalec – član svetovalnice, ki je odgovoren za reševanje poslanega terminološkega vprašanja in pripravo odgovora, ki ga pošlje v potrditev skrbniku svetovalnice (samo pri samostojnih namestitvah terminološkega portala, ki niso povezani s <u>Terminološko svetovalnico</u> Inštituta za slovenski jezik Frana Ramovša ZRC SAZU)





Vloge, ki jih lahko pridobijo vsi registrirani uporabniki terminološkega portala, če želijo sodelovati pri izdelavi določenega terminološkega vira:

Administrator terminološkega vira – registrirani uporabnik, ki v urejevalniku ustvari nov terminološki vir in ima vse pravice pri urejanju tega vira, k sodelovanju lahko povabi tudi druge registrirane uporabnike, ureja metapodatke in lahko vse podatke tudi izbriše

Urednik terminološkega vira – registrirani uporabnik, ki ga administrator terminološkega vira povabi k izdelovanju in urejanju slovarskih sestavkov, terminološkega vira ne more izbrisati

Strokovni in jezikovni pregled – administrator terminološkega vira lahko določi pravico urejanja vsebine posameznih slovarskih sestavkov tudi registriranim uporabnikom samo za jezikovni ali strokovni pregled, pri čemer lahko ti sodelavci urejajo samo vsebino slovarskih sestavkov, ne morejo pa urejati metapodatkov

Registrirani uporabnik

Uporabnik, ki v obrazec vnese veljavni e-naslov, si izbere uporabniško ime in geslo ter potrdi politiko zasebnosti in pogoje uporabe, s tem pa pridobi pravico uporabe storitev luščenja, urejanja, uvoza in izvoza terminoloških virov, zastavljanja terminoloških vprašanj in komentiranja

Neregistrirani uporabnik

Uporabnik terminološkega portala, ki lahko poizveduje po terminih in brska med objavljenimi terminološkimi odgovori, ne more pa uporabljati drugih storitev

Uporabniki se na terminološkem portalu identificirajo z uporabniškim imenom in e-naslovom ter geslom. Hranjenje osebnih podatkov je urejeno s Politiko zasebnosti in Pogoji uporabe ob registraciji.



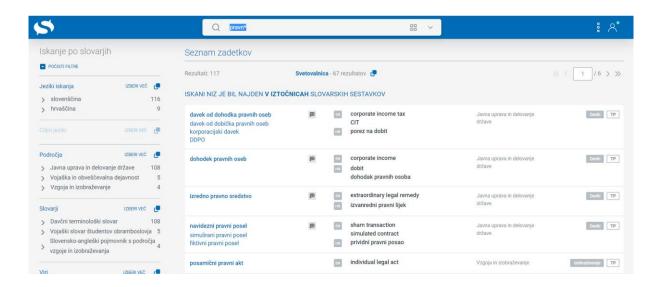


3 Iskanje

Iskanje informacij po terminoloških virih je osnovna funkcija terminološkega portala, ki jo uporablja večina uporabnikov. Zato je ključna enostavnost in hitrost iskanja ter ustrezen prikaz podatkov o najdenih zadetkih.

Na terminološkem portalu so na voljo naslednji načini iskanja:

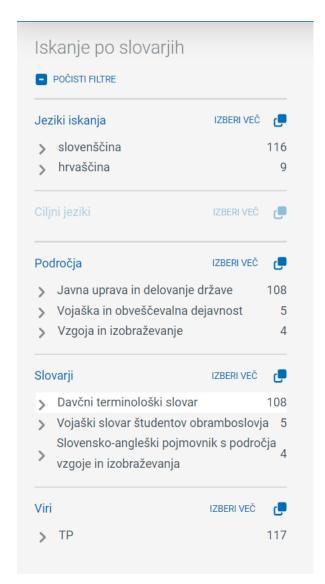
1. vpis niza znakov v iskalno polje, ki ponudi prikaz zadetkov v terminoloških virih in v svetovalnici z osnovnimi podatki. Iskanje pri malih in velikih črkah je poenostavljeno tako, da velikost vpisane črke ne vpliva na zadetke. Iskalnik vedno najde tako malo kot veliko črko.



Zadetke je mogoče tudi filtrirati in izbrati le določeno vrsto zadetkov. Možno je izbrati enega, več ali vse izbrane jezike, področja, slovarje ali vire. Ne glede na vrsto iskanja je iskalnik prosto dostopen za vse uporabnike, torej za uporabo iskalnika ni potrebna registracija. Prikazujejo se podatki iz vseh vključenih virov na portal in vseh z API-jem povezanih spletnih mest.







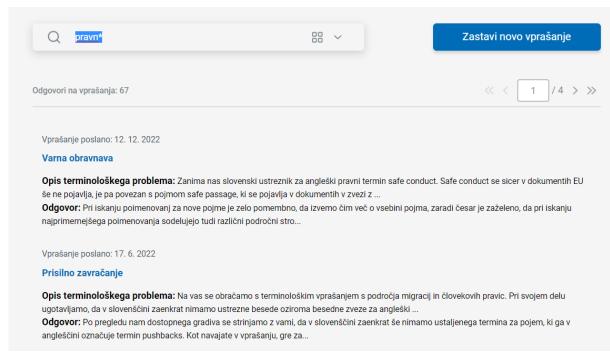
- 2. Prikaz celotnega slovarskega sestavka po izbiri enega od zadetkov:
 - a. na terminološkem portalu za vse vire, vključene v terminološki portal,



b. v svetovalnici med terminološkimi odgovori,







- c. na izvirnem spletnem mestu (npr. Terminologišče, Termania) za vire, ki so povezani s terminološkim portalom prek API-ja za prenos podatkov.
- 3. Prikaz informacij o terminološkem viru:

Uporabnikom je dostopen s klikom na aktivno povezavo, npr. Davčni terminološki slovar, natančnejši vsebinski opis terminološkega vira. Vsak terminološki vir ima strukturirana vnosna polja, s katerimi uporabniki izvejo, kdo je sodeloval pri nastajanju vira, na katero področje spada, torej, kako so urejeni podatki v terminološkem viru.







3.1 Osnovno iskanje

Osnovno iskanje je privzeta oblika iskanja, zato smo to iskanje naredili čim bolj preprosto. Iskalnik ima klasično iskalno polje, v katero se vpiše niz znakov, ki ga želimo najti. Iskani niz se bo ločeno iskal po slovenskih terminih, tujih terminih in drugih elementih slovarskega sestavka.

Iskanje besed in besednih zvez

Poleg iskanja ene besede je v terminologiji pogosto iskanje večbesednih terminov. Če bi v iskalno polje napisali zvezo *davčna odločba*, bo iskalnik našel vse tiste slovarske sestavke, kjer v določenem elementu hkrati nastopata besedi *davčna* in *odločba*. Vrstni red besed ni pomemben - besedi sta lahko ena za drugo ali pa je med njima še kakšna druga beseda. Presledek v tem primeru torej predstavlja operator IN.

Če želimo najti besedno zvezo, kjer morata besedi stati skupaj in v točno določenem vrstnem redu, vpišemo iskalni pogoj "davčna odločba". Dvojna narekovaja torej določata iskanje po besedni zvezi.

Iskanje s posebnimi ukaznimi znaki

Omogočili smo tudi uporabo nadomestnih znakov – vprašaja (?) in zvezdice (*). ? nadomešča natanko en poljuben znak, * pa nadomešča od nič do neskončno poljubnih znakov.

Drugi znaki, kot so ! (za izločanje niza), # (za od do) in nekateri drugi, pri iskanju po analizi terminoloških portalov v Sloveniji in tujini niso zares pogosto uporabljeni, zato jih nismo omogočili.

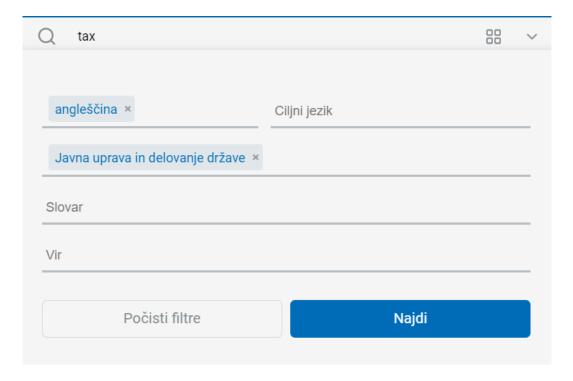
Nadomestna znaka? in * je mogoče uporabiti tudi pri iskanju po besednih zvezah.

3.2 Napredno iskanje

Napredno iskanje poleg osnovnega iskalnega polja za vnos iskalnega niza omogoča še iskanje po jezikih, področjih, slovarjih in tudi virih.







3.3 Prikaz in razvrščanje zadetkov

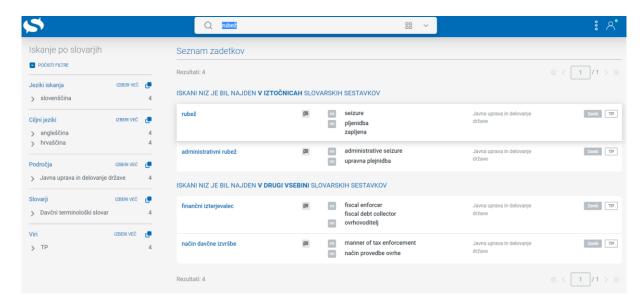
Zadetki iskanja se razvrščajo po naslednjem vrstnem redu:

- 1. Slovarski sestavki, kjer je slovenski termin enak iskalnemu nizu.
- 2. Slovarski sestavki, kjer slovenski termin vsebuje iskalni niz.
- 3. Slovarski sestavki, kjer je tuji termin enak iskalnemu nizu.
- 4. Slovarski sestavki, kjer tuji termin vsebuje iskalni niz.
- 5. Slovarski sestavki, kjer sinonimi vsebujejo iskalni niz.
- 6. Slovarski sestavki, kjer drugi elementi vsebujejo iskalni niz.

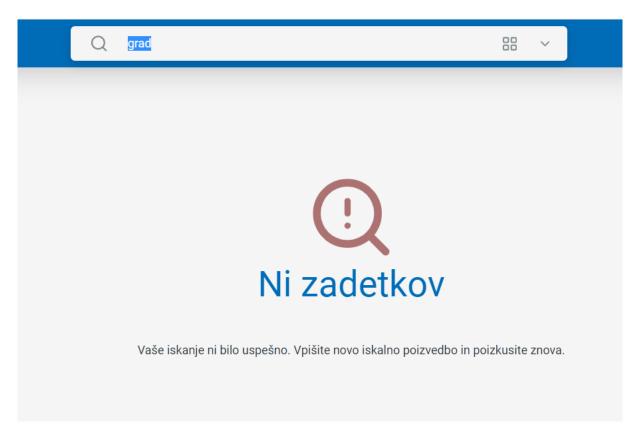
V okviru vsake od naštete podmnožice zadetkov se zadetki uredijo po abecedi slovenskih terminov.







Če iskanje ni uspešno, ker iskani niz ne ustreza nobenemu slovarskemu sestavku, iskalnik opozori: *Ni zadetkov*.

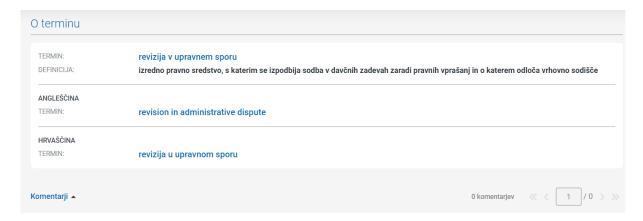


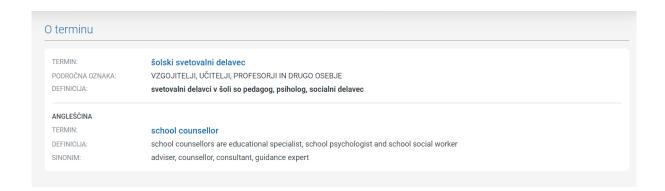




3.4 O terminu

Izbira enega termina na seznamu zadetkov prikaže vse podatke o izbranem terminu. Obseg podatkov je odvisen od izbranega terminološkega vira, ker nimajo vsi termini na terminološkem portalu enakovrstnih informacij.





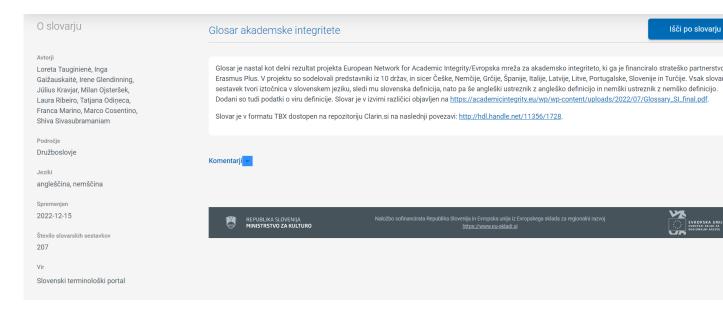
3.5 O slovarju

Osnovne informacije o terminološkem viru so na voljo v razdelku *O slovarju*, ki vsebuje podatke, katera področja pokriva terminološki vir, kateri jeziki so vključeni, kdo so njegovi avtorji, koliko slovarskih sestavkov ima, kdaj je bil nazadnje spremenjen, pa tudi opis, kako je terminološki vir nastajal. Registrirani uporabniki lahko administratorju terminološkega vira oddajo tudi svoj komentar.

Primer opisa terminološkega vira, ki je objavljen na Slovenskem terminološkem portalu: Glosar akademske integritete











4 Luščenje

Osnova za izdelavo vsakega terminološkega vira je seznam terminov, ki se imenuje *geslovnik*. Oblikovanje geslovnika lahko poteka na več načinov. Izbira terminov je odvisna od avtorjev oz. urednikov slovarja. Registrirani uporabniki imajo na terminološkem portalu tri osnovne možnosti:

- a) Termine lahko v urejevalnik dodajajo neposredno. Pri tem se opirajo na svoje znanje, izkušnje in poznavanje strokovnega področja. Takšen način je primeren zlasti za področja, ki še nimajo ustreznih strokovnih in znanstvenih besedil v slovenščini, predloge poimenovanj pa bi radi razširili v širši strokovni skupnosti.
- b) Druga možnost je izpisovanje terminov iz strokovnih besedil in prav tako vnašanje neposredno v urejevalnik.
- c) Tretja možnost je uporaba avtomatskega postopka luščenja terminoloških kandidatov iz strokovnih in znanstvenih besedil in priprava geslovnika iz seznama rezultatov. To metodo omogoča tudi terminološki portal s posebnim modulom za luščenje. Uporabnik lahko pripravi svoj specializirani korpus strokovnih besedil ali izbere področje v že oblikovanem in označenem korpusu OSS, v katerem so združena besedila, objavljena na Nacionalnem portalu odprte znanosti. S pomočjo orodja za luščenje je mogoče hitro izluščiti terminološke kandidate, kar poenostavi in skrajša uvodno fazo izdelave terminološkega slovarja.

Luščilnik za svoje delovanje uporablja temeljne jezikovne tehnologije za slovenščino, in sicer tokenizacijo, lematizacijo in oblikoskladenjsko označevanje, pri statističnem vrednotenju terminološkosti pa se za primerjavo uporabljajo lematizirani frekvenčni seznami (n-grami) referenčnega korpusa Gigafida 2.0. Kakovost izluščenih terminoloških kandidatov je odvisna od kakovosti in uravnoteženosti izbranih besedil. Besedila korpusa OSS so že predhodno oblikoskladenjsko označena, lastna uporabnikova pa je treba še označiti, zato lahko postopek luščenja traja dlje.

Modul za luščenje terminoloških kandidatov je na voljo v okviru terminološkega portala, kot programska koda in samostojno orodje pa je dostopen tudi na <u>GitHub</u>-u.

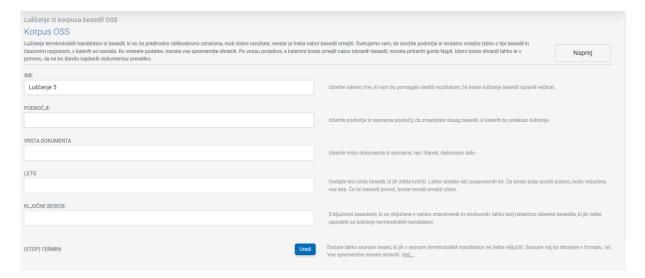
4.1 Postopek luščenja

V nadaljevanju je natančneje opisan postopek luščenja na terminološkem portalu:





- 1. Uporabnik pripravi nabor besedil, iz katerih želi pridobiti terminološke kandidate za določeno strokovno področje. Pri tem ima dve možnosti:
 - Izbira besedil iz korpusa OSS, ki je dostopen tudi na konkordančnikih v okviru Clarin.si. Ta korpus se bo predvidoma dopolnjeval enkrat letno. Besedila je mogoče izbirati po področju, vrsti dokumenta, letu in ključnih besedah, saj je največje dovoljeno število besedil za luščenje omejeno.



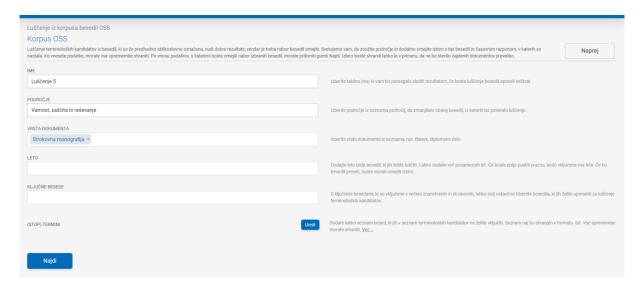
Pred začetkom luščenja in izbiro gumba Naprej, je treba izbrati področje s seznama, prav tako na spustnem seznamu izbere vrsto dokumenta, npr. *izvirni znanstveni članek*, *univerzitetni učbenik z recenzijo* itd., dodatno izbiro lahko omeji z leti in ključnimi besedami. Šele nato lahko izbere možnost *Naprej* v desnem kotu zgoraj.

Po dodanih kriterijih uporabnik dobi število dokumentov.

Primer izbiranja: V spustnih menijih izberemo področje *Varnost, zaščita in reševanje* in vrsto dokumenta *izvirni znanstveni članek* in želimo najti vse dokumente, ki ustrezajo tema dvema pogojema. Izberemo ukaz Najdi v desnem kotu spodaj.



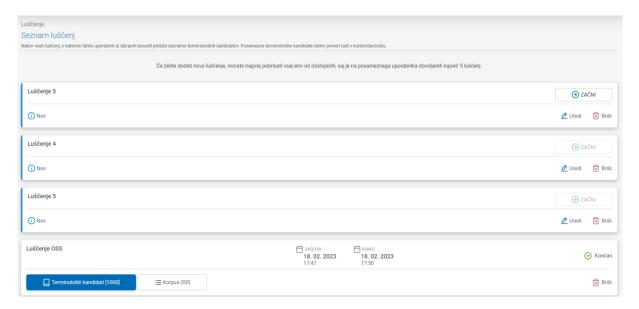




Iskalnik nam ponudi 75 dokumentov, ki jih shranimo:



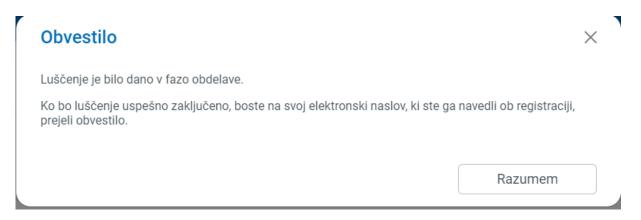
Luščenje se pojavi na seznamu luščenj in lahko izberemo ukaz Začni.



Ker je luščenje postopek, ki zahteva več spominskega prostora, registrirani uporabnik dobi sporočilo, da bo o zaključku luščenja obveščen na e-naslov, ki ga je navedel ob registraciji. Z izbiro gumba *Razumem* se postopek luščenja začne izvajati.







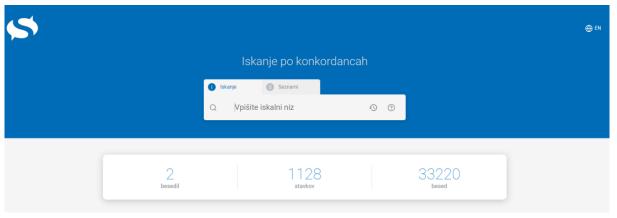
Nalaganje lastnih datotek je omogočeno v nekaterih pogostih formatih (.pdf, .doc, .docx, .txt). Uporabnike opozarjamo, da luščilnik najbolje deluje, če so vsebine v čisti tekstovni obliki, pri drugih formatih pa so mogoče napake pri pretvorbi. Najprej je treba naložiti datoteke:



Po nalaganju dokumentov izberemo ukaz *Naprej* in nato v seznamu osnovnih luščenj izberemo ukaz *Začni*, po koncu luščenja pa dobimo obvestilo na e-naslov.

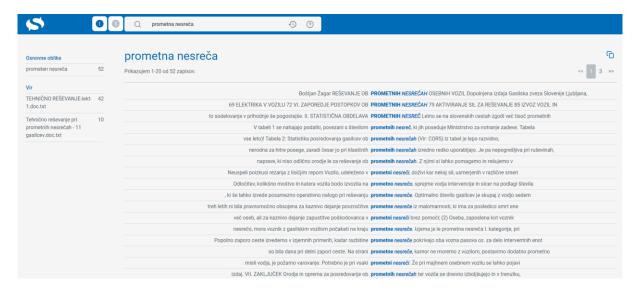
2. Avtomatsko luščenje

Rezultat luščenja sta seznam terminoloških kandidatov (v kanonični obliki, tj. v imenovalniku) s statističnimi podatki (npr. TF, TF-IDF), s pomočjo katerih jih uporabnik lahko filtrira in ureja, ter korpus besedil, v katerem bo uporabnik lahko preverjal pojavljanje terminoloških kandidatov in primere rabe v konkordančniku.









Hibridni sistem luščenja je zasnovan na podlagi prepoznavanja izbranih besednovrstnih vzorcev in statističnega razvrščanja kandidatov. Preizkusili in razvili smo naslednje metode:

- Klasične statistične mere stabilnosti besednih zvez (npr. MI, PMI), mere za primerjavo specializiranega in referenčnega korpusa (npr. LUIZ-CF), statistične mere specifičnosti za izbrano strokovno področje glede na širšo zbirko besedil (npr. TF-IDF) in druge klasične mere za luščenje terminoloških kandidatov (C/NC value). Za primerjavo z referenčnim korpusom luščilnik interno uporablja korpus Gigafida 2.0, ki je označen z istimi orodji oz. s frekvenčnim seznamom, izdelanim na podlagi tega korpusa (frekvenčni seznam n-gramov lem). Za primerjavo s širšim korpusom besedil so uporabljena besedila Nacionalnega portala odprte znanosti.
- Naprednejše metode z uporabo kontekstualnih besednih vložitev, kjer je bilo preizkušeno nenadzorovano učenje s primerjavo kontekstualnih vektorjev splošnega in domenskega korpusa ter nadzorovano učenje s prepoznavanjem terminov v učnih korpusih.

Različne mere ter njihove kombinacije so bile sistematično ovrednotene na testnih množicah, da smo lahko identificirali optimalno kombinacijo mer za končni sistem. Izluščenim terminom je pripisana kanonična oblika. Pri tem smo uporabili oblikoskladenjske oznake samega korpusa za iskanje termina v imenovalniku ter ustrezne zunanje jezikovne vire (npr. Sloleks oz. sezname terminov, ki so že vključeni v repozitorij Clarin.si).





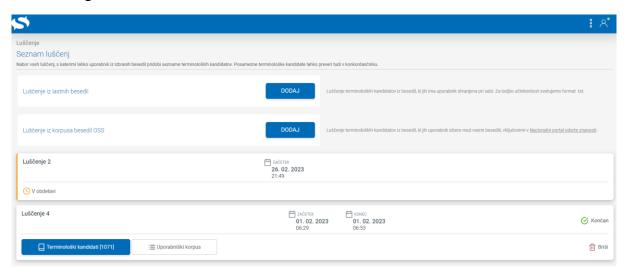
V korpusu besedil smo razpoznali tudi stavke, ki lahko uporabniku pomagajo kot osnova pri tvorjenju definicije. Metode temeljijo na razpoznavanju dobrih primerov glede na informacijo o dolžini stavka, informacijo o mestu termina v stavku in besednoskladenjskih informacijah.

3. Seznam terminoloških kandidatov (s pripadajočimi podatki) in oba korpusna konkordančnika (za OSS in korpus lastnih besedil) sta v razdelku za luščenje znotraj terminološkega portala na voljo uporabniku za nadaljnje delo in uporabo (npr. izvoz v standardni format).

Modul za luščenje in označevanje terminov v besedilih je na voljo vsem registriranim uporabnikom. Vse uporabnike, ki bodo izdelovali svoj terminološki vir, spodbujamo k uporabi modula za luščenje.

4.2 Seznam luščenj

Osnovna stran luščenja vsebuje seznam luščenj, ki so v enem od štirih stanj - v urejanju, v obdelavi, prekinjeno ali končano. Vsak uporabnik lahko shrani podatke za največ 5 luščenj v seznamu. Ob zahtevi po novem luščenju mora uporabnik izbrisati eno od luščenj, da lahko začne novega.



4.3 Dodajanje in urejanje luščenj

Pri dodajanju ali urejanju novega luščenja je treba vnesti nekaj obveznih podatkov. Med obvezne podatke sodi ime luščenja, pred luščenjem pa je treba naložiti želena besedila ali določiti parametre, na osnovi katerih bodo izbrana besedila iz korpusa OSS. Med opcijske





podatke sodi vnos seznam neželenih terminov, t. i. stop seznam, ki naj jih program v vsakem primeru izloči, zato jih v končnem seznamu terminoloških kandidatov ne bo.





5 Urejanje

Terminološki viri nastajajo v različnih okoljih. Ustvarjajo jih strokovnjaki v javnih in zasebnih ustanovah, raziskovalci, prevajalci, študenti in drugi. Da bi vsem tem skupinam olajšali delo, smo izdelali spletni urejevalnik za izdelavo terminoloških virov, s katerim lahko avtorji urejajo terminologijo svojega področja, ob tem pa jim bo prek terminološkega portala na voljo tudi pomoč skrbnikov portala v zvezi s strukturo terminološkega vira in metodologijo dela.

Vsi slovarji imajo enako strukturo zapisa slovarskega sestavka. Za nove terminološke vire, ki bodo nastali na portalu, bo mogoče prilagajati elemente slovarskega sestavka od najbolj preprostega z iztočnico v slovenskem jeziku in definicijo ali tujim terminom do kompleksnejšega z večjim številom elementov.

Pri zasnovi in izdelavi urejevalnika smo upoštevali, da uporabniki niso profesionalni sestavljalci terminoloških virov, zato smo oblikovali orodje, ki je enostavno za uporabo, a kljub temu ponuja vse potrebne funkcije za urejanja terminološkega vira.

Omogočena sta uvoz in izvoz podatkov iz in v običajne datotečne formate ter večuporabniško delo z različnimi vlogami uporabnikov ter dodajanje večpredstavnih podatkov in povezav na zunanje vire.

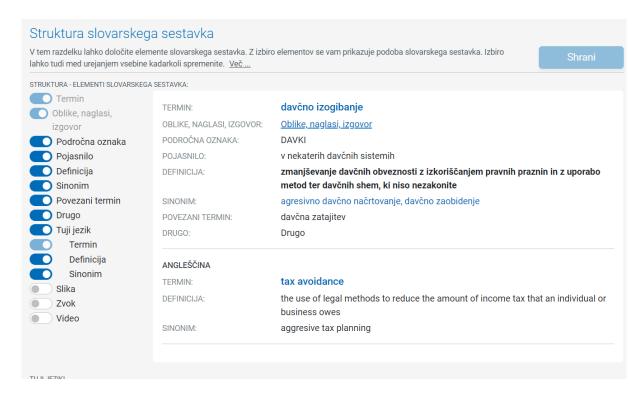
Urejevalnik je na voljo samo registriranim uporabnikom.

5.1 Struktura slovarskega sestavka

Vsi elementi slovarskega sestavka so izbirni z izjemo termina v slovenskem jeziku, ki mu mora biti dodana definicija ali tuji termin. Na sliki je prikazan slovarski sestavek, ki ima izbrane vse elemente, ki so na voljo.







Posamezni elementi slovarskega sestavka (primerjaj tudi slovarček na začetku dokumenta):

- Termin = poimenovanje pojma v slovenskem jeziku
- Področna oznaka = oznaka, ki je v terminološkem viru uporabljena za večjo skupino pojmov
- Pojasnilo = okoliščine, ki sicer niso del pojma, ponujajo pa dodatne informacije o njem, npr. časovna pojasnila (do leta 2007, v 19. stoletju, med letoma 1988 in 1992) in natančnejša področna pojasnila (v kazenskem procesnem pravu, v biodinamični pridelavi, pri reševanju na vodi).
- Definicija = umestitev pojma v pojmovni sistem z določitvijo nadrejenega pojma, npr. vse davke opisujemo na enak način in začnemo definicijo z davek, nato pa opišemo značilnosti pojma v razmerju do drugih pojmov v skupini, zlasti osnovne značilnosti in razlike, npr. davek na zapuščino je davek, ki obdavčuje prenos premoženja umrle osebe na pravne naslednike.
- Sinonim = poimenovanje, ki se poleg termina prav tako pojavlja v nekem jeziku za označevanje istega pojma
- Povezani termin = termin, ki označuje sorodni, vendar ne isti pojem, npr. *davčna optimizacija* označuje uporabo zakonitih možnosti za zmanjševanje davčne osnove, da bi davčni zavezanec plačal čim nižji davek, *davčno izogibanje* pa označuje izkoriščanje pravnih praznin, pri čemer je spet osnovni namen plačilo čim nižjega zneska davka.





Uporabnik lahko izbere vrsto povezave med termini, in sicer *sorodni*, *ožji*, *širši*, pri čemer mora izbirati med termini, ki jih je vključil v svoj terminološki vir.

- Drugo = Polje je namenoma odprto, da lahko uporabniki vključijo tisto vsebino, ki se jim zdi potrebna, npr. navajajo vire, primere rabe, opozorila o terminološkem dogovoru itd.
- Tuji jezik = Izhodišče terminološkega portala predvideva terminologijo v slovenskem jeziku, uporabnik pa lahko izbere, katere informacije želi dodati še v tujem jeziku, npr. samo tujejezični termin ali tudi definicijo v tujem jeziku, sinonime ...

5.2 Faze urejanja

Urejanje terminoloških virov je sestavljeno iz več faz. Na Slovenskem terminološkem portalu lahko administrator terminološkega vira aktivno vplivajo na zadnji dve fazi.



Predlog: V terminološkem viru so samo terminološki kandidati ali pa je uporabnik uvozil svoj seznam terminov. Tega seznama ni mogoče objaviti, ampak je treba dodati vsaj še en podatek (definicijo ali tujejezični termin) pri vsakem slovarskem sestavku.

V urejanju: Slovarski sestavki v terminološkem viru so v fazi, ko se dodajajo in oblikujejo elementi, ki jih je administrator terminološkega vira izbral v strukturi slovarskega sestavka. V tej fazi lahko sodelujejo vsi registrirani uporabniki, ki jih je administrator terminološkega vira povabil v skupino.

Urejeno: Slovarski sestavki v terminološkem viru so pregledani in dokončani. Administrator terminološkega vira ga želi objaviti, zato pošlje sporočilo skrbniku terminoloških virov.

Ponujeni sta še dve možnosti, ki ju administratorji terminološkega vira slovarja lahko izberejo in uporabijo:

Strokovno pregledano: Terminološki vir je pregledal področni strokovnjak ali recenzent, ki ni avtor definicij.

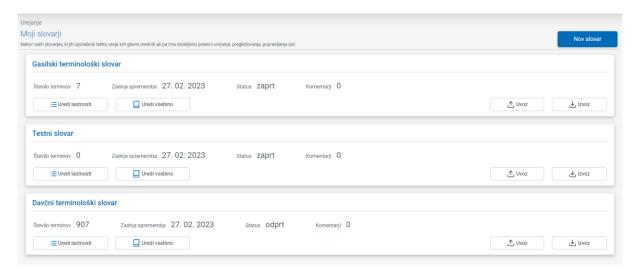
Jezikovno pregledano: Terminološki vir je pregledal jezikoslovec in odpravil morebitne jezikovne pomanjkljivosti.



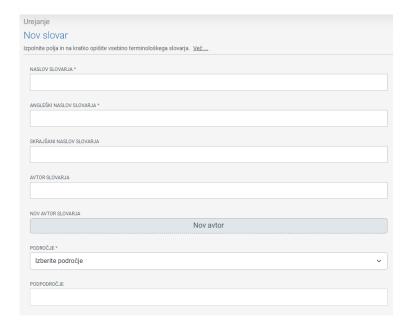


5.3 Nov slovar

Registrirani uporabnik lahko ureja vse terminološke vire, ki so zbrani v zavihku Moji slovarji. Vidni so vsi terminološki viri, ki jih je sam začel izdelovati ali pa mu jih je drug uporabnik dovolil urejati. Viri so razvrščeni padajoče po datumu zadnje spremembe, uporabnik pa lahko vidi, koliko slovarskih sestavkov vsebujejo, število oddanih komentarjev in status, pri čemer *odprt* pomeni, da je terminološki vir viden vsem, tudi neregistriranim uporabnikom terminološkega portala, *zaprt*, da je viden samo tistim registriranim uporabnikom, ki lahko ta vir urejajo, in *v odpiranju*, ki kaže na to, da je skupina zaključila z delom in čaka na potrditev za objavo.



Registrirani uporabnik se lahko odloči tudi za ustvarjanje novega slovarja z izbiro gumba desno zgoraj *Nov slovar*, pri čemer je treba vpisati podatke. Vsa polja, ki zahtevajo obvezne podatke, so označena z zvezdico.







- Naslov terminološkega vira: Uporabnik mora vnesti celoten naslov terminološkega vira, kakor bo zabeležen v bibliografskih podatkih.
- Angleški naslov terminološkega vira: Celotni naslov terminološkega vira v angleščini smiselno dopolnjuje podatke pri izmenjavi informacij z drugimi terminološkimi portali, zato je predvideno, da ga vnese administrator terminološkega vira sam in se ne generira strojno.
- Skrajšani naslov terminološkega vira: Unikatno kratko ime terminološkega vira, ki lahko obsega največ 15 znakov, olajša prepoznavanje informacij na seznamu iskalnih zadetkov. Če uporabnik podatkov ne vpiše, se dodajo samodejno.



- Avtor terminološkega vira: Terminološki viri so verodostojnejši, če so znani avtorji vnosov, zato naj uporabnik doda vse avtorje z imenom in priimkom. Pri virih, ki nastajajo povsem na novo, so to administrator terminološkega vira in drugi dodani uporabniki s pravicami, pri dovoljeni predelavi že obstoječih virov, pa je treba navesti tudi avtorje izvirnika.
- **Področje:** Uporabnik iz spustnega seznama področij izbere eno osnovno **področje,** na katero sodi terminološki vir, npr. *fizika*, *šport in igre*, *vzgoja in izobraževanje*.
- Podpodročja: Uporabnik s spustnega seznama podpodročij izbere eno ali več ožjih podpodročij, ki bolj natančno določajo vsebino terminološkega vira, npr. atletika, smučanje, alpinizem, če je nadrejeno področje šport. Če uporabnik ustreznega podpodročja ne najde, ga lahko doda (vnesti je treba podatke tako v slovenščini kot angleščini), vendar mora novo podpodročje najprej potrditi administrator portala, ki lahko preveri, ali podatek že obstaja.
- **Struktura slovarskega sestavka:** Uporabnik v shemi z izbiro elementov določi, katere informacije bo vseboval terminološki vir.



• **Tuji jeziki:** Če je uporabnik v shemi določil, da bodo v terminološkem viru tudi termini v tujem jeziku, mora izbrati jezike v spustnem seznamu, sicer portal javlja napako *Niste vpisali tujih jezikov*.





TUJI JEZIKI			
Niste vpisali tujih jezikov.			

Ob ustvarjanju slovarja se v Osnovnih podatkih odpre tudi polje, ki je namenjeno opisu vsebinske zasnove terminološkega vira:



Dodano je tudi polje za vnos ISSN oznake.

Dodajanje sodelavcev terminološkega vira:

Pri izbiri posameznega terminološkega vira lahko uporabnik med *Lastnostmi* doda tudi druge registrirane uporabnike portala in jim dodeli pravice. Poznati mora njihovo uporabniško ime. Seznam uporabnikov seveda ni dostopen, zato je predviden osebni stik med avtorji novega terminološkega vira, če pa bi posamezniki imeli težave, pa se lahko po pomoč obrnejo tudi na administratorja portala. Če uporabniško ime ni pravilno vpisano, se izpiše obvestilo:



Uporabniške vloge lahko dodaja tudi skrbnik slovarjev.







Shranjevanje podatkov

Uporabniki morajo biti pozorni, da spremembe podatkov ves čas shranjujejo, sicer se lahko spremembe izgubijo. Vsak uporabnik je opozorjen, če želi zamenjati stran pred shranjevanjem.



Področne oznake

Področne oznake so namenjene lažji organizaciji pojmov zlasti pri večjih terminoloških virih. Področne oznake so podatki, ki se razlikujejo med posameznimi terminološkimi viri. Smiselno je, da so te oznake čim krajše, navadno enobesedne ali dvobesedne, lahko so tudi v obliki krajšav. Znotraj terminološkega vira je smiselno imeti enak način poimenovanja oznak, npr. agrarna geografija, demogeografija, klimatogeografija ali agr. geogr., demogeogr., klimatogeogr.

Poleg podatkov, ki jih pripravijo uporabniki, so samodejno generirani naslednji podatki:

- datum in čas ustvarjanja terminološkega vira (zabeležen je tudi datum zadnje spremembe),
- ID terminološkega vira enotna oznaka oblike "XX9999" (npr. "TP0012"), pri čemer je "XX" oznaka portala, "9999" pa zaporedna številka (ID) terminološkega vira na portalu.





6 Svetovanje

Iskanje po objavljenih terminoloških odgovorih, ki nastajajo v <u>Terminološki svetovalnici</u> <u>Inštituta za slovenski jezik Frana Ramovša ZRC SAZU</u>, je na voljo vsem uporabnikom. Nova terminološka vprašanja lahko zastavijo samo registrirani uporabniki. Svetovanje je namenjeno pomoči pri terminoloških problemih na področjih, kjer še ni izdelanih terminoloških virov, ali pa odgovora ne morete najti. Svetovanje na Slovenskem terminološkem portalu izvajajo sodelavci <u>Terminološke sekcije Inštituta za slovenski jezik Frana Ramovša ZRC SAZU</u>.

6.1 Pošiljanje vprašanj

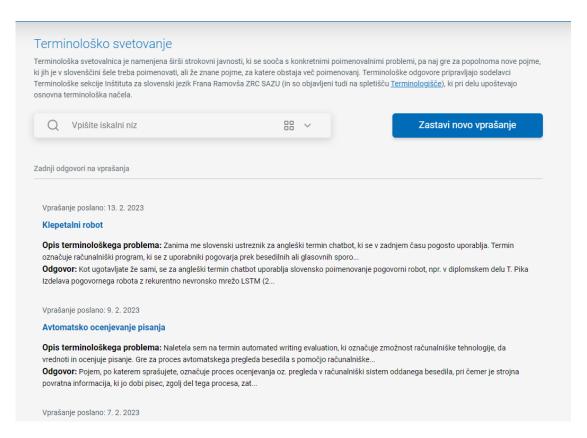
Pri postavljanju vprašanj o najprimernejšem terminu so zelo pomembni posredovani podatki. Dovolj podatkov o terminološkem problemu omogoči svetovalcem, da svetujejo, katera rešitev bi bila najbolj ustrezna z vidika terminološke vede. Zato je zelo pomembno, da pri zastavljanju vprašanja v obrazec vnesete čim več podatkov o terminu, predvsem kaj ta pomeni, zelo koristni pa so tudi podatki o besedilih, v katerih se pojavlja, morebitne že obstoječe poimenovalne rešitve (ko več terminov označuje isti pojem), tujejezični ustrezniki itd.

6.2 Objava odgovorov

Odgovor bo objavljen v Terminološki svetovalnici Inštituta za slovenski jezik Frana Ramovša ZRC SAZU in prikazan tudi na Slovenskem terminološkem portalu. Na e-naslov, ki ste ga navedli ob registraciji, boste prejeli odgovor, preden bo objavljen.











7 Administracija

Portal je administriran.

7.1 Osnovne nastavitve

Administratorski del portala omogoča dodeljevanje pooblastil izbranim uporabnikom, ki jih administrator portala določi za skrbnike terminoloških virov, skrbnike svetovalnice, lahko pa dodeljuje tudi vloge znotraj posameznih terminoloških virov, če administrator terminološkega vira zaprosi za pomoč.

7.2 Povezave s portali

Slovenski terminološki portal je javno dostopno spletno mesto. Programska koda pa je na voljo tudi na repozitoriju GitHub Clarin.si, zato je omogočena tudi lastna namestitev terminološkega portala. Če ste se odločili za to, potem lahko povežete svoj novi portal z drugimi terminološkimi portali, tudi s Slovenskim terminološkim portalom, in ob soglasju administratorjev teh portalov prikazujete tudi njihove terminološke vire. Pri tem morate vnesti podatke o povezanem portalu.

Dvočrkovne oznake portalov so specifične in unikatne za vsak posamezni portal. Med terminološkimi viri na povezanem terminološkem portalu lahko izberete vse terminološke vire, lahko pa samo nekatere, zlasti terminološke vire tistih področij, ki jih na vašem terminološkem portalu ni.





8 Kolofon

Pri izdelavi terminološkega portala in njegovih vsebin smo sodelovali:

Vodja vsebinske zasnove: Mateja Jemec Tomazin, ZRC SAZU Vodja tehnične zasnove in izvedbe: Miro Romih, Amebis

Oblikovalec: Samo Kramberger

Sodelujoče ustanove in sodelavci:

Amebis: Miro Romih, Anton Romšak, Luka Romih, Jure Artiček, Miha Stele, Aljaž Grilc

Institut Jožef Stefan: Senja Pollak, Hanh Thi Hong Tran, Vid Podpečan, Matej Martinc, Andraž

Repar, Marko Pranjić, Nada Lavrač, Andraž Pelicon, Tomaž Erjavec

UL FF: Špela Vintar

UL FRI: Boštjan Slivnik, Danijel Skočaj, Marko Robnik Šikonja, Vladimir Batagelj (sicer UL FMF), Ivan Bratko, Peter Rogelj (sicer UP FAMNIT),

UL FU: Polonca Kovač, Maja Klun, Jernej Podlipnik (sicer odvetnik in predavatelj), Andreja Kostelec (sicer samostojna raziskovalka in predavateljica), Nika Hudej (sicer svetovalka US RS) **UM FERI:** Marko Ferme, Kristjan Žagar, Ivan Kovačič, Klemen Kac, Milan Ojsteršek, Damjan Strnad, Matjaž Divjak, Marko Bizjak, Matjaž Debevec, Ines Kožuh, Irena Lovrenčič Držanič **ZRC SAZU:** Mateja Jemec Tomazin, Simon Atelšek, Tanja Fajfar, Karmen Nemec, Jera Sitar,